Examen de Mi-Session – INF1833

Modélisation Complexe, Multicolinéarité et Diagnostic

Travail présenté en équipe de 5 minimum ou 6 maximum

Présentaion : 21 octobre 2021

Date de remise des livrables : 19 octobre 2025 à 22h00
Livrables :

1. Un rapport d'analyse structuré de 10 à 15 pages.
2. Une présentation orale de 10 à 15 minutes.
3. Fichier jupyternotbook ou python
4. L'annexe A de cet énoncé

Contexte et Objectif

Cet examen de mi-session est une évaluation complète de vos compétences en modélisation statistique. L'objectif est de construire le meilleur modèle de régression possible pour prédire le prix d'un véhicule, en portant une attention particulière à l'identification et à la gestion des problèmes courants en régression.

Jeu de Données : Prédiction du Prix des Voitures

Le jeu de données contient les caractéristiques techniques et les prix de vente de différents modèles de voitures. Votre mandat est de répondre à la question de recherche suivante :

Quelles sont les caractéristiques techniques qui influencent le plus le prix de vente (`price`) d'une automobile ?

Variables à votre disposition :

- **Variable dépendante (Y) :** `price` (Prix du véhicule en dollars).
- **Variables prédictives (X) potentielles (8 variables) :**
  - `horsepower` (Puissance du moteur, en chevaux).
  - `engine_size` (Taille du moteur, en pouces cubes).
  - `curb_weight` (Poids à vide du véhicule, en livres).
  - `city_mpg` (Consommation en ville, en miles par gallon).
  - `highway_mpg` (Consommation sur autoroute, en miles par gallon).
  - `wheelbase` (Empattement, en pouces).
  - `car_width` (Largeur du véhicule, en pouces).
  - `fuel_type` (Type de carburant : 'gas' ou 'diesel', qualitative).

Questions de l'Examen

Votre rapport doit répondre de manière rigoureuse et structurée aux questions suivantes.

Partie 1 : Analyse Exploratoire des Données (EDA)

1. Menez une **analyse exploratoire complète et pertinente** du jeu de données. Votre objectif est de comprendre en profondeur la nature des données, la distribution des variables clés et d'identifier les relations potentiellement importantes pour la modélisation future du prix (`price`).

   Votre analyse doit inclure, **sans s'y limiter** :
   - Un **résumé numérique** des variables quantitatives, incluant non seulement les mesures de tendance centrale et de dispersion, mais aussi les mesures de forme (asymétrie, aplatissement).
   - Des **visualisations appropriées** pour illustrer la distribution de la variable `price` et d'autres variables pertinentes (ex : histogrammes, boîtes à moustaches, diagrammes en violon, etc.).
   - Une **analyse approfondie des relations** entre les variables prédictives et la variable cible, ainsi que des relations entre les prédicteurs eux-mêmes. Utilisez pour cela des outils numériques (matrice de corrélation) et graphiques (nuages de points, carte de chaleur).

   À l'issue de cette analyse, **formulez une synthèse** qui présente vos hypothèses initiales sur les variables qui vous semblent les plus prometteuses pour expliquer le prix d'un véhicule, et qui identifie les défis potentiels pour la modélisation (ex : fortes corrélations, distributions très asymétriques, présence de valeurs aberrantes, etc.).

Partie 2 : Construction et Sélection du Modèle

2. **Modélisation et Multicolinéarité :**
   - Construisez un modèle de régression linéaire multiple (`Modèle Complet`) en utilisant **toutes les variables explicatives** fournies. N'oubliez pas de gérer la variable qualitative `fuel_type`.
   - Calculez et analysez le **Facteur d'Inflation de la Variance (VIF)** pour chaque prédicteur. Le modèle souffre-t-il d'un problème de multicolinéarité ? Justifiez votre réponse.
3. **Raffinement et Sélection du Modèle :**
   - Sur la base de votre diagnostic de multicolinéarité et de la significativité des coefficients, proposez et mettez en œuvre une stratégie de remédiation pour obtenir un modèle plus robuste.
   - Présentez votre `Modèle Final` et justifiez sa supérioriété par rapport au `Modèle Complet` en comparant leurs $\mathbf{R^2}$ **ajusté** et **AIC/BIC**.
4. **Interprétation du Modèle Final :**
   - Présentez le sommaire des résultats de votre `Modèle Final`.
   - Interprétez avec précision les coefficients des variables `horsepower` et `curb_weight`, en respectant la clause "toutes choses égales par ailleurs".

Partie 3 : Diagnostic Complet du Modèle Final

La performance d'un modèle ne se résume pas à son R^2 ajusté. Cette partie évalue votre capacité à diagnostiquer de manière critique la validité et la fiabilité de votre `Modèle Final`.

5. **Analyse des Hypothèses Fondamentales (LINE) :**
   — **Linéarité & Homoscédasticité :**
      (a) Analysez le graphique des résidus en fonction des valeurs prédites. L'hypothèse de **linéarité** est-elle respectée ? Justifiez.
      (b) L'hypothèse d'**homoscédasticité** est-elle respectée ? Décrivez la dispersion des résidus pour identifier toute forme d'hétéroscédasticité et discutez des conséquences.
   — **Normalité des Erreurs :**
      (c) Analysez le graphique Q-Q des résidus. L'hypothèse de **normalité** est-elle satisfaite ? Décrivez le comportement des points.
   — **Indépendance des Erreurs :**
      (d) Discutez de l'hypothèse d'**indépendance des erreurs**. Pourquoi est-elle généralement considérée comme respectée dans ce contexte ?
6. **Analyse des Points Atypiques et Influents :**
   (a) Identifiez les **valeurs aberrantes (outliers)** et les **points à fort effet de levier (leverage points)** en utilisant un graphique approprié.
   (b) Calculez la **distance de Cook** pour détecter les **points influents**. Y a-t-il des observations qui dépassent les seuils critiques ?
   (c) Si vous avez identifié un point influent, quelle serait la démarche professionnelle à suivre ? Expliquez pourquoi la suppression automatique n'est pas recommandée.

Partie 4 : Conclusion et Synthèse

7. **Jugement Final sur le Modèle :**
   — En tenant compte de **toute votre analyse de diagnostic (Partie 3)**, portez un jugement critique et nuancé sur la fiabilité globale de votre `Modèle Final`.
   — Selon ce modèle, quels sont les facteurs les plus importants qui déterminent le prix d'une voiture ? Recommanderiez-vous l'utilisation de ce modèle pour des prédictions ? Justifiez.

Annexe A — Contributions individuelles (obligatoire)

Nom	Tâches principales (2–3 lignes)	Heures estimées	Signature